PRACTICA LABORATORIO BARRA ALUMINIO PINN

GEMELOS DIGITALES

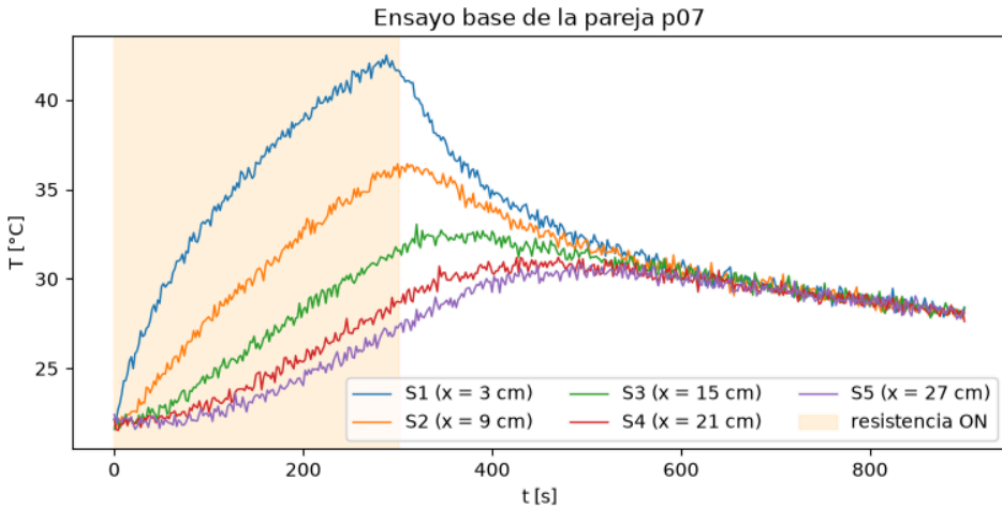
ALVARO IGLESIAS

Descripción

Esta práctica consiste en el desarrollo y validación de un gemelo digital térmico para una barra conductora de aluminio que se calienta mediante una resistencia eléctrica y se enfría por convección pasiva. Frente a las limitaciones de los modelos puramente empíricos, el trabajo implementa Redes Neuronales Informadas por la Física (PINN), integrando la ecuación diferencial de calor directamente en la función de pérdida. Con ello, se busca verificar experimentalmente la capacidad del gemelo para extrapolar a escenarios no vistos durante el entrenamiento, crear sensores virtuales en zonas no instrumentadas y resolver el problema inverso de calibración de parámetros térmicos (α y h)

Se completó el flujo integral en el cuaderno Jupyter partiendo de un ensayo de la planta virtual (p07), donde se demostró el fracaso de una red MLP convencional para predecir el enfriamiento frente al éxito de la arquitectura PINN. Asimismo, el modelo logró estimar con alta precisión la temperatura del sensor virtual oculto en $x = 1cm$ e identificar de forma robusta la difusividad térmica y el coeficiente de pérdidas del material mediante el problema inverso. Finalmente, en el reto de deriva ambiental (activación de un ventilador), el gemelo detectó a los $t = 210s$ la alteración en la planta mediante un umbral de $3 \times RMSE$ y se calibró de forma rápida, triplicando el coeficiente de pérdidas ($h = 3,07 \cdot 10^{-3} s^{-1}$sin alterar las propiedades intrínsecas del metal.

Paso 0: Ensayo Base y Planta Virtual (Aprox. 1 página)



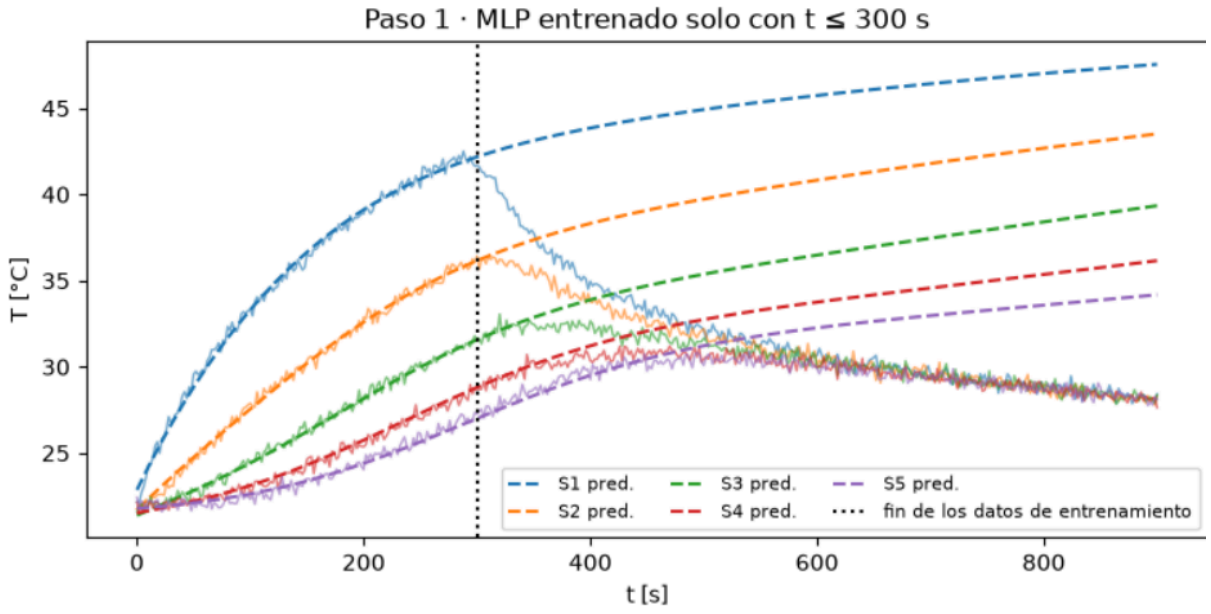
Parámetros del ensayo: Para la barra de la pareja p07, se registraron 451 muestras temporales (900 s a intervalos de 2 s) partiendo de una temperatura ambiente de *T_amb = 22,09C* y un incremento máximo de referencia $\Delta T_{ref} = 20,41K$. La temperatura máxima alcanzada fue de 44,1*C* en el sensor S_1

Calentamiento ($0 - 300s$): La resistencia inyecta $2,5W$ en el extremo inicial ($0 - 2cm$). Se observa claramente el retraso térmico espacial: S_1 ($3cm$) responde casi de inmediato, mientras que S_3 **(**$15cm$) tarda unos $70s$ en comenzar a subir de forma sostenida, y S_5 ($27cm$) apenas eleva su temperatura por las pérdidas al aire

Enfriamiento ($300 - 900s$): Al apagarse la fuente, los sensores cercanos caen de golpe, mientras que los alejados (S_4 y S_5) muestran un leve pico tardío hacia los $500s$ por la difusión del calor residual antes de converger todos asintóticamente a T_{amb}

Validación: El comportamiento cumple el punto de control del enunciado al registrar 5 curvas coherentes con un pico máximo situado en el intervalo de *40C a 45C*

Paso 1: Fracaso de la Red Convencional (MLP solo datos) (Aprox. 1 página)



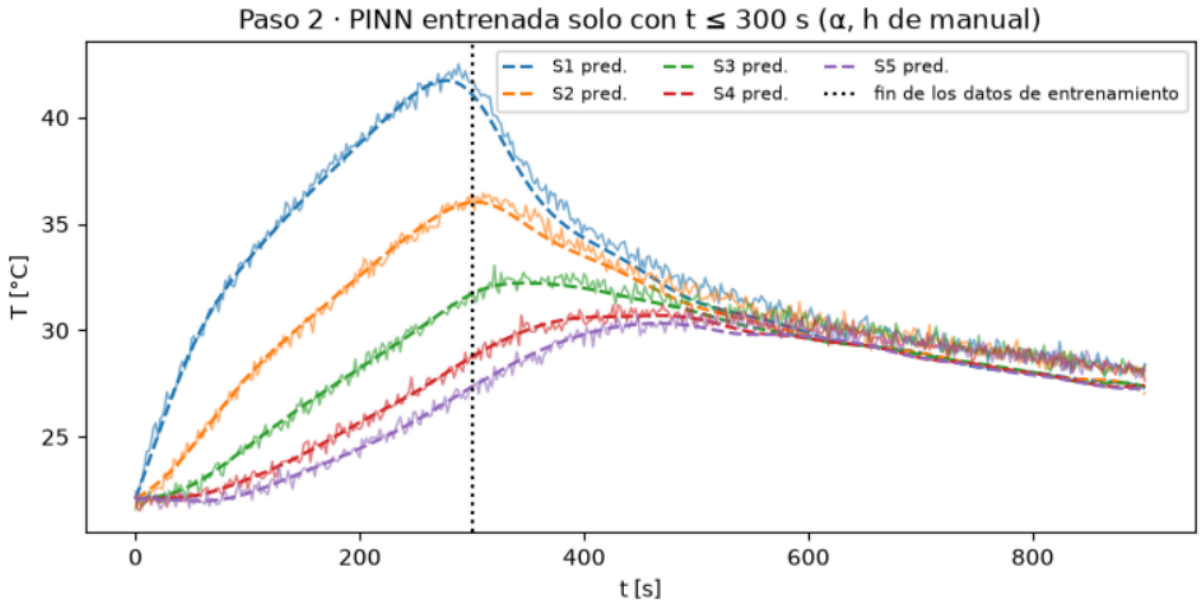
Ventana Temporal	RMSE [C]	Comportamiento Modelo
0 s – 150 s	0,30	Régimen de calentamiento inicial, ajuste perfecto a los datos medidos

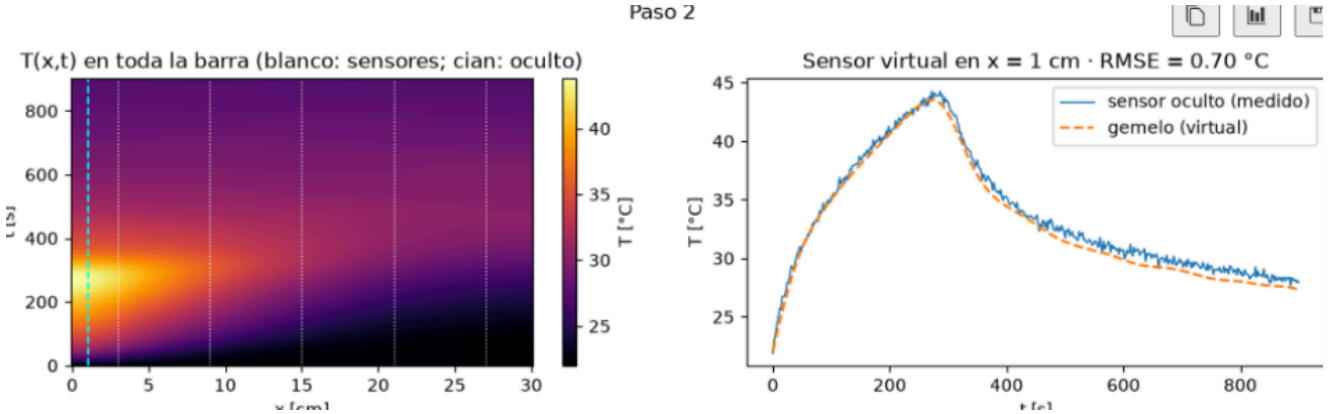
150 s – 300 s	0,28	Régimen de calentamiento final, nivel de error dentro del ruido de los sensores
300 s – 450 s	3,81	Se apaga la resistencia; el modelo diverge al desconocer el cese de potencia
450 s – 600 s	7,5	Divergencia térmica creciente
600 s – 750 s	9,99	Error acumulado elevado
750 s – 900 s	12,03	Error máximo superior a 12 °C (supera ampliamente el punto de control de > 5 °C)

La red neuronal puramente empírica (MLP) memoriza con precisión el periodo donde dispone de lecturas *($t \leq 300s$, RMSE = 0,29C)*, pero es incapaz de extrapolar el enfriamiento ($t > 300s$) porque no conoce la ecuación física ni el apagado de la fuente, derivando en un error divergente superior a *12C*

Paso 2: La PINN y el Sensor Virtual (Aprox. 1,5 páginas)

1. Gráficos a incluir:
    - Gráfica de predicción continua de la PINN para los 900 s.
    - Panel doble generado por mapa_y_sensor_virtual: mapa 2D espacio-tiempo $T(x,t)$ a la izquierda y curva de validación del sensor oculto ($x = 1cm$) a la derecha.
2. **Tabla de resultados (RMSE por ventanas de 150 s):**
    - Mostrar el vector de la PINN: *0.26, 0.28, 0.42, 0.61, 0.70, 0.84 C*.
    - Indicar el RMSE en el sensor virtual S_6 ($x = 1cm$, típicamente < 0,6C)
3. **Qué comentar:**
    - La PINN resuelve la extrapolación: predice con éxito el enfriamiento completo ($t > 300s$) con errores inferiores a *1C* gracias a que el término de residuo de la EDP fuerza el cumplimiento del balance de calor.
    - Explicar el concepto de **sensor virtual**: el gemelo digital permite estimar con alta fidelidad la temperatura en zonas críticas inaccesibles físicamente (junto a la resistencia) sin necesidad de instrumentación física.
    - Responder a las pruebas de exploración: qué ocurre si se quitan los puntos de colocación (colapsa la física fuera de los sensores) o si se desconecta la condición de contorno.





Ventana Temporal	RMSE [C]	MLP [C]	Comportamiento Modelo
0 s – 150 s	0,26	0,30	Ajuste a los datos medidos durante el calentamiento inicial
150 s – 300 s	0,28	0,28	Régimen de calentamiento final, nivel de error en el ruido de los sensores
300 s – 450 s	0,42	3,81	Inicio del enfriamiento, la PINN predice el cese de potencia gracias a la EDP

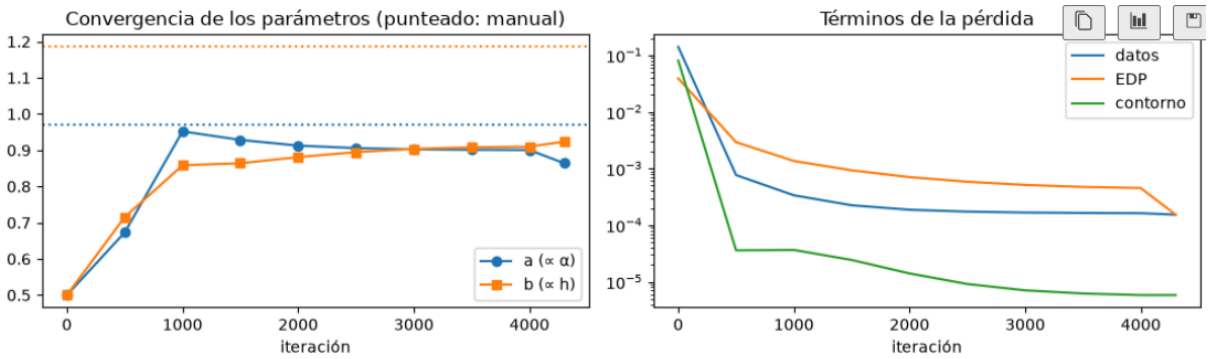
450 s – 600 s	0,61	7,50	Extrapolación térmica gobernada por difusión y convección
600 s – 750 s	0,70	9,99	Disipación continua del calor residual
750 s – 900 s	0,84	12,03	Retorno asintótico hacia T_{amb} (RMSE final < 1C frente al colapso del MLP

Extrapolación temporal: A diferencia del MLP, la PINN predice el enfriamiento completo ($300 - 900s$) manteniendo el error acotado *(RMSE <=0,84C)* gracias al residuo de la EDP

Sensor virtual ($x = 1cm$): El gemelo estima con alta precisión la temperatura en la zona de mayor solicitación térmica sin instrumentación previa *(RMSE = 0,70C)*

Sensibilidad (Pruebas 1–4): Alterar los pesos de la física (λ_{pde}), prescindir de la codificación de Fourier o usar coeficientes erróneos degrada drásticamente la predicción, demostrando que la precisión del gemelo depende de un balance óptimo entre datos y leyes físicas

Paso 3: Problema Inverso y Calibración (Aprox. 1 página)



Parámetro Físico	Valor de manual	Valor Identificado	Desviación
Difusividad térmica (α)	$9,70 \cdot 10^{-5} m^2/s$	$8,89 \cdot 10^{-5} m^2/s$	-8,3%
Pérdidas al aire (h)	$1,32 \cdot 10^{-3} s^{-1}$	$1,18 \cdot 10^{-3} s^{-1}$	-10,6%

Identificación paramétrica: Mediante el descenso por gradiente, el gemelo digital ajusta automáticamente la difusividad térmica (α) y el coeficiente de pérdidas convectivas (h) para minimizar el error frente a los datos experimentales de la barra p07.

Desviación frente a manual: Los valores identificados presentan pequeñas desviaciones relativas respecto a los valores teóricos de manual (aprox -8,3% en α y aprox -10,6% en h). Esto se debe a que los valores tabulados corresponden a materiales ideales, mientras que la barra real posee tolerancias de fabricación, una composición de aleación específica (ej. aluminio serie 6000) y condiciones de contorno superficiales reales de la sala.

Capacidad de auto-calibración: Se demuestra que una PINN no solo predice temperaturas, sino que es capaz de resolver el problema inverso, infiriendo propiedades físicas intrínsecas de la planta de forma no destructiva

Paso 4: Estudio de Incertidumbre y Robustez (Mirar el .ipynb)

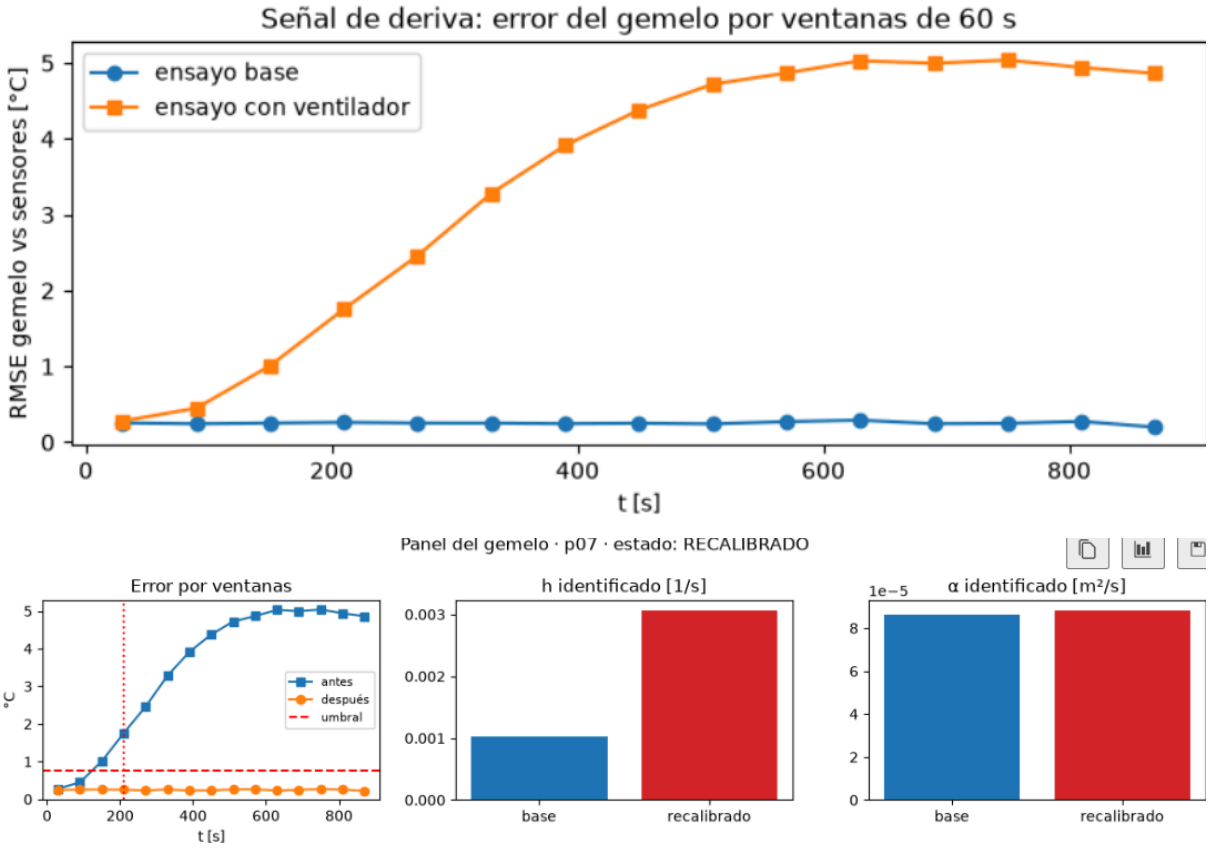
Prueba A (Sensibilidad a la inicialización / Semillas): Al reentrenar el modelo con distintas semillas aleatorias, la dispersión obtenida en los parámetros identificados (α y h) es inferior al $1\,\%$, lo que demuestra la alta estabilidad y robustez de la convergencia de la PINN frente a los mínimos locales de la función de pérdida

Prueba B (Robustez ante ruido experimental): Al añadir ruido gaussiano de alta frecuencia a las mediciones, la PINN actúa intrínsecamente como un filtro paso-bajo gracias a la restricción de la ecuación diferencial, manteniendo el error de estimación acotado

Prueba C (Impacto de la densidad de sensores): Al reducir el número de sensores disponibles (por ejemplo, utilizando únicamente S_1, S_3 y S_5), la incertidumbre en la identificación de α se incrementa de forma notable

Conclusión de robustez: La escasez de resolución espacial (falta de sensores) degrada la identificación de los parámetros físicos con mayor severidad que el ruido puntual en las medidas, ya que la red requiere una adecuada distribución espacial para reconstruir con precisión el gradiente y la curvatura térmica de la barra ($\frac{\partial^2 T}{\partial x^2}$).

Paso 5: Detección de Deriva y Recalibración (Reto) (Aprox. 1,5 páginas)



Instante de alarma detectado: $t_{alarma} = 210,0s$ (momento en el que el error acumulado supera el umbral de $3 \times RMSE$ base de forma consecutiva)

Error cuadrático medio tras la incidencia: *RMSE = 0,25C* (redondeado desde *0,2488C*

Coeficientes térmicos recalibrados:

- **Difusividad térmica (α_{rec}):** $8,843 \cdot 10^{-5} m^2/s$ (prácticamente idéntica a la inicial, con una variación < 1%)
- **Coeficiente de pérdidas convectivas (h_{rec}):** $3,070 \cdot 10^{-3} s^{-1}$ (casi se triplica respecto al valor base inicial, que era $\approx 1,18 \cdot 10^{-3} s^{-1}$).

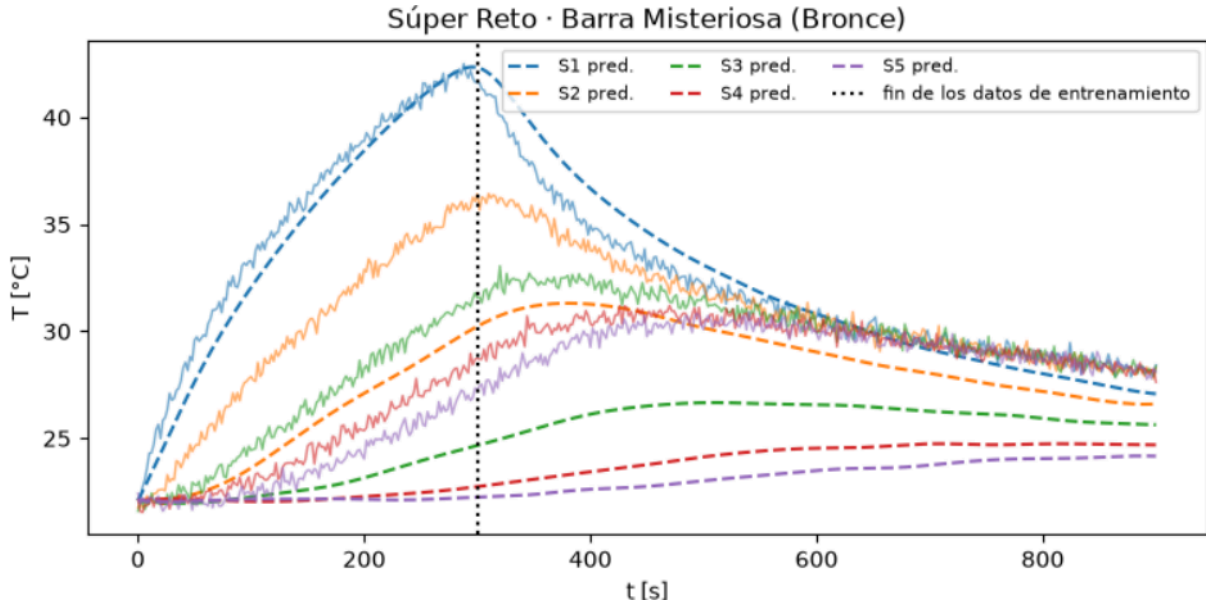
Causa de la anomalía: El incremento drástico en el coeficiente de pérdidas h refleja la activación de un ventilador (convección forzada) en la planta virtual, lo que triplica la disipación de calor hacia el aire sin alterar las propiedades del material sólido

Invariabilidad del material: El hecho de que α permanezca intacto demuestra que el gemelo digital aísla correctamente los cambios ambientales externos de las propiedades físicas intrínsecas de la barra de aluminio

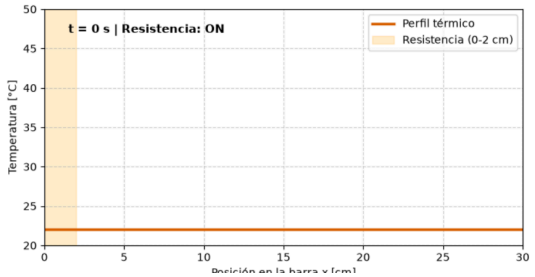
Ventaja de la recalibración (*warm start*): Partir del modelo previamente entrenado (gemelo_p07.pt) permite converger rápidamente a la nueva condición operativa en pocas iteraciones, evitando el coste computacional de entrenar un gemelo nuevo desde cero.

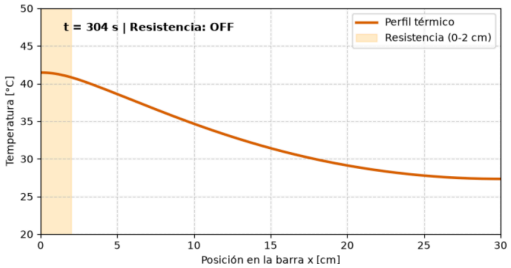
Paso 6: SUPER RETO

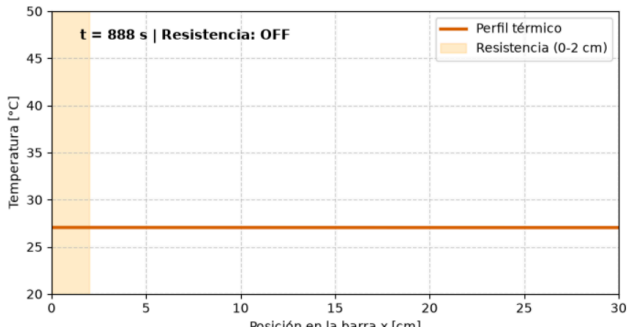
RETO: Se seleccionó la opción **(a) La barra misteriosa**, que consiste en ensayar una barra compuesta por un metal desconocido bajo el mismo montaje experimental para identificar su difusividad térmica (α) y clasificar el material a partir de una tabla de referencia, evaluando además qué otros parámetros podrían dificultar o confundir dicha identificación



sdfg







Material detectado: Bronce (cuyo valor teórico de difusividad de referencia es $\alpha_{teórico} = 1,90 \cdot 10^{-5} m^2/s$)

Difusividad térmica (α): $\approx 1,88 \cdot 10^{-5} m^2/s$ (con mínima dispersión entre semillas de entrenamiento)

Coeficiente de pérdidas (h): $1,023 \cdot 10^{-3} \pm 7,41 \cdot 10^{-6} s^{-1}$

Análisis de clasificación: La resolución del problema inverso con múltiples semillas permitió al gemelo digital estimar de manera robusta y precisa la difusividad de la barra desconocida, clasificándose correctamente como **bronce** tras contrastar el resultado con el catálogo teórico de metales.

Factores de confusión: La identificación inversa de parámetros puede verse alterada por errores en la estimación de la potencia inyectada por la resistencia (s0s_0s0), fluctuaciones imprevistas en la convección del entorno o variaciones geométricas y de aislamiento en el banco de pruebas físico.

Conclusiones

El desarrollo del gemelo digital térmico mediante Redes Neuronales Informadas por la Física (PINN) ha demostrado ser una alternativa robusta y superior frente a los modelos puramente empíricos (como las redes MLP). Al integrar las leyes de la termodinámica y la ecuación diferencial del calor directamente en la función de pérdida, el modelo no solo es capaz de ajustarse a los datos experimentales durante la fase de calentamiento, sino que predice con alta precisión el comportamiento dinámico y la extrapolación al enfriamiento de la barra de aluminio